

AI 赋能地铁客流预测:算法创新与现实挑战

冯紫嫣¹, 王宪喆¹, 李想²

(1. 北京化工大学 经济管理学院, 北京 100029; 2. 北京理工大学 管理学院, 北京 100081)

摘要: 地铁系统凭借其高效的运载能力与便捷的服务模式, 逐渐成为我国各大城市交通网络骨干。精准预测客流需求有助于促进地铁运营规划与列车运行组织。然而, 地铁网络规模的扩增和智慧城市建设步伐的迈进, 多源数据维度显著增加, 且受天气变化、特殊事件、其他交通模式等多重外部因素的干扰, 地铁系统在客流预测精度和管理效能方面面临着严峻的挑战。以机器学习为代表的 AI 技术为解决复杂地铁客流预测任务提供了解决思路。本文通过综述近年来国内外交通与管理领域期刊的相关论文, 从 AI 技术赋能地铁客流预测任务出发对现有文献进行分类, 探讨了地铁客流预测领域所面临的现实挑战和未来研究方向。尽管不同预测方法下相关文献所探讨的预测任务与分析角度各异, 但 AI 技术正引领地铁客流预测向更复杂、更现实、更智能的方向迈进。

关键词: 地铁系统; 客流预测; AI 赋能; 机器学习; 大语言模型

中图分类号: U121 **文献标识码:** A **文章编号:** 2097-0145(2025)06-0032-09 **doi:** 10.11847/fj.44.6.32

0 引言

地铁系统作为城市居民日常通勤的重要方式, 在引领和支撑城市发展、满足人民出行、缓解交通拥堵等方面发挥了重要作用。客流预测是优化地铁运力调度与提升运营效率的关键环节。通过地铁乘客出行需求的精细化预测, 管理者能够精准实施车底周转、调整班次、时刻表优化等运营调整方案, 实现地铁运输系统的降本增效。然而, 随着居民出行需求的持续增加和地铁线网规模的不断扩大, 地铁系统的运营管理正面临着严峻挑战。以北京市为例, 2024 年全市地铁客运总量达 36.22 亿人次, 日均 989.61 万人次。与此同时, 地铁网络在线路数量、运营里程等方面迅猛发展, 到 2025 年, 北京市将形成由 30 条运营线路组成的地铁交通网络, 总长达 1177 公里。持续增长的出行需求、密集的线路布局、复杂的网络结构、灵活的运营模式产生海量数据的同时, 为提高地铁客流预测精度提供了可行路径。

大数据、人工智能(AI)等技术的快速发展为提升地铁客流精准预测提供了思路。2008 年 9 月 Nature 出版“Big Data”特刊和 2011 年 2 月 Science 出版“Dealing with Data”特刊推动了大数据和 AI 的发展。根据 Nature 的分析报告, 截至 2023 年 12 月, Scopus 数据库中在标题或摘要提及 AI 或 AI 相关关键词的论文比例为 8%, 而 10 年前为 2%。随着 AI 技术的不断进步, 机器学习、深度学习和大语言

模型作为 AI 的重要分支, 得到不同领域学者的广泛关注。本文通过综述近 15 年发表在国内外主流交通和管理领域期刊的相关论文, 从不同维度特征编码能力出发, 梳理当前 AI 赋能地铁客流预测方法的研究现状。基于此, 从精度提升、效率增强、透明预测和决策对齐四个方面, 探讨地铁客流预测领域面临的现实挑战和未来研究方向。

1 AI 赋能地铁客流预测分类法

作为时间序列预测的经典应用场景, 地铁客流预测早期研究主要采用计量经济学与统计学方法。通过分析历史时序数据的统计特征, 捕捉“过去”与“未来”之间的关联关系, 构建参数化或非参数化模型, 以实现地铁客流预测的目标^[1]。通常, 计量模型假设历史数据服从某一特定分布, 通过估计其中的核心参数, 优化模型对数据的拟合效果。然而, 这种方法考虑的特征数量有限, 制约了模型对全量数据信息的充分利用。随着大数据和计算力的迅速发展, 以机器学习为代表的 AI 方法逐渐成为地铁客流预测的前沿方法。作为一种强调“轻模型, 重算法”的新型预测范式, 机器学习能够有效捕捉大规模数据中的复杂模式与非线性关系。与计量方法注重参数的准确估计不同, 机器学习模型更关注预测精度的提升, 凭借其强大的数据挖掘能力, 为解决复杂场景下地铁客流预测问题提供了新的思路。

传统机器学习通常由算法专家设计特征工程,

收稿日期: 2024-12-30

基金项目: 国家自然科学基金资助项目(72401018, W2411066, U2469202); 北京市科技新星计划资助项目(20230484421)

通讯作者简介: 李想, 北京理工大学经济管理学院教授, 博士生导师, 研究方向: 交通运输管理, 大数据决策。E-mail: 6120240105@bit.edu.cn。

人工提取数据中的关键信息^[2]。然而,地铁系统数据复杂且多源,包括时间维度的动态性、空间结构的关联性和多源数据的异质性,使得依赖强模型假设与人工筛选的特征工程逐渐成为限制其预测性能提升的障碍。深度神经网络的发展为解决上述问题提供了新的方向。深度学习在处理非结构化高维数据方面具有卓越的表示学习能力^[3],能够自适应提取数据的多层次特征,突破了传统方法在特征提取与模式识别上的局限,通过有效整合地铁客流的复杂时空分布特征以及外部交通系统等多源特征,进一步提升了地铁客流预测的准确性。

近年来,大语言模型(LLMs)的兴起颠覆了传统 AI 方法,在自然语言处理、计算机视觉等领域取得了重大突破,为解决复杂任务提供了一种全新的视角。一些学者开始探索将 LLMs 应用于时间序列预测任务^[4]。与深度学习等有监督学习为核心的特征编码方式不同,LLMs 通过预训练整合大量不同领域知识,为地铁客流预测任务的特征提取提供了全新的知识驱动范式。这种范式超越了传统深度学习的单一领域特征编码,通过微调预训练模型,高效迁移跨领域知识到特定地铁客流预测任务。特别地,LLMs 能够从多源异构数据中提取高度抽象化的特征,凭借其强大的语义理解能力,深度识别和解释数据之间的深层关系,提高地铁客流预测任务的泛化能力和可解释性,推动相关研究迈向更高水平。

由近 15 年在交通和管理领域期刊发表的地铁客流预测相关论文的年度分布情况可知,总体而言,该领域发文总量自 2019 年起呈现显著增长态势,随着深度学习、LLMs 等 AI 技术的突破,其在地铁客流预测中的优势逐渐显现,吸引了众多学者的关注。具体来看,计量模型相关研究在 2020 年前保持相对稳定,此后经历先升后降的波动,其在整体研究数量上略多于传统机器学习模型,源于计量模型在数据稀缺场景(如新线开通、突发事件等)中展现出的独特优势^[5]。传统机器学习模型的应用趋势与计量模型相似,呈现“平稳—增长—回落”的三阶段特征。深度学习模型的应用自 2019 年起显著增加,随后保持强劲增长势头。LLMs 相关应用自 2022 年才开始出现,当前已进入快速发展阶段。目前发表地铁客流预测相关论文数量最多的期刊包括 *IEEE Transactions on Intelligent Transportation Systems*、*Journal of Advanced Transportation*、《铁道科学与工程学报》《铁道运输与经济》、*Transportation Research Part C: Emerging Technologies* 等。

2 传统计量预测方法

传统计量模型是基于统计学和经济学原理构

建的数学预测方法,包括时间序列基准模型:历史平均模型、差分整合移动平均自回归(ARIMA);线性回归模型:最小二乘法、逻辑回归等。在地铁客流需求预测发展早期,传统计量模型被应用于单一站点客流、单一起讫(OD)客流或地铁系统客流总量预测任务^[6]。这一类问题通常被建模为时间序列预测问题,即仅基于历史客流数据,推断未来客流的演化规律。以一天内客流预测问题为例,考虑不同时间粒度将一天离散为 T 个时段, d_t 代表 t 时段内地地铁客流人数。给定历史 h 期的历史客流数据 $\{d_{t-h}, d_{t-h+1}, \dots, d_{t-1}\}$ 及其相关特征矩阵 x ,旨在得到未来 l 期的客流预测结果 $\{\hat{d}_t, \hat{d}_{t+1}, \dots, \hat{d}_{t+l}\}$

$$\hat{d}_t, \hat{d}_{t+1}, \dots, \hat{d}_{t+l} = F(d_{t-h}, d_{t-h+1}, \dots, d_{t-1}, x) \quad (1)$$

本质上,该任务可以被转化为一个基于历史数据和相应特征的最优预测模型 $F(\cdot)$ 的寻优过程。通过传统计量方法对历史客流数据进行建模,挖掘数据中的周期性、趋势性以及随机性特征,为地铁客流预测提供了理论基础和技术支持^[7]。由于传统计量模型通常基于特定的客流发生模式假设,当结合外部特征(如天气、事件等)构建回归框架时,其在异常客流识别和新增站点场景方面展现出独特优势^[5]。例如,Lyu 等^[8]构建了多元线性回归模型对新增站点客流需求进行预测,在训练数据有限的场景下,该模型具有更优的预测精度。这一发现为数据稀缺条件下的交通需求预测提供了参考。

然而,传统计量预测方法考虑的特征数量有限^[9]。一方面,其难以自动处理高维特征,导致对大规模数据中复杂模式和非线性关系的捕捉能力不足;另一方面,该方法的预测实时性表现欠佳,预测精度有限,难以满足地铁短时客流预测对实时响应和高准确性的双重需求。因此,近年来在地铁客流预测研究中,单一的传统计量预测方法已较少被采用。

3 机器学习预测方法

随着大数据技术和计算能力的显著提升,以机器学习为代表的 AI 方法近年来取得了突破性进展。越来越多的学者开始将机器学习模型引入地铁客流预测研究领域,推动该领域从传统计量方法向数据驱动范式转变。机器学习中的经典建模方法主要包括基于距离的最近邻方法:K 近邻法;基于核函数的回归方法:岭回归、高斯过程回归和支持向量回归;基于树结构的模型方法:回归树、随机森林、极端梯度提升树和轻量级梯度提升树等。这些模型能够有效处理不确定性高、非线性强的动态系统,且无需预设参数或依赖严格的先验假设,仅需足够的历史数据即可实现高精度预测^[2]。此外,地铁客流数据通常具有多源、多尺度等特征,而

集成学习通过整合专注于不同特征的模型,模型间的相互补充可以降低因数据复杂性导致的过拟合或欠拟合风险,有效处理多样化信息,减小模型偏差和方差^[10]。常见的集成学习方法包括 Bagging、Boosting 和 Stacking 等,已成功应用于地铁客流预测研究中^[11]。

在基于传统机器学习的地铁客流预测研究中,大多沿袭了传统计量模型的建模思路,将客流需求预测问题简化为时间序列预测任务,其在整合地铁客流空间特征方面仍存在明显局限,难以有效捕捉多站点间客流分布的空间异质性以及复杂的时空关联特性。因此,一些研究尝试将地铁网络拓扑结构异质性考虑进来。韩皓等^[12]通过融合地铁线网结构特征与单站点的时序客流数据,构建了基于轻量级梯度提升树的地铁短时客流预测模型。另有一些研究通过站点筛选或聚类,降低多站点耦合所引发的高维特征复杂性。周家中和张殿业^[13]基于地铁网络距离划分车站的影响范围,提出分距离影响带的线型和指数型空间权重系数方程,构建空间加权预测模型。

尽管机器学习方法相较于传统计量方法展现出更优的高维特征处理能力,但其在时空关系建模上存在明显短板,既无法有效表示地铁网络的复杂拓扑结构,也难以学习客流数据中的跨时段长期依赖模式。更为关键的是,这类方法的特征构建高度依赖领域专家的先验知识,缺乏时空特征的自适应识别机制,极易陷入维度灾难。在模型特征编码方面,传统机器学习特征非线性拟合能力有限,特别是在应对地面交通波动、公共政策调整、突发事件冲击以及社交媒体舆情等复杂外部因素时,难以有效捕捉高维特征空间中全局模式与局部特征间的非线性交互作用,导致传统机器学习方法难以适应智慧交通场景下高维度、强动态、多关联的地铁客流精准预测需求。

4 深度学习预测方法

深度神经网络技术的飞速发展为破解上述难题开辟了新路径。凭借其多层次特征编码和自适应架构,展现出较强的特征编码能力和模型表达能力。通过端到端的表示学习范式,深度学习能够自动挖掘非结构化高维数据中隐含的多尺度特征模式,使其在复杂场景下具备更强的泛化性能。目前,学界面向不同建模需求,构建了多元化深度神经网络体系,例如,基于时序建模的循环神经网络(RNN)、擅长局部特征提取的卷积神经网络(CNN)、专攻图结构数据处理的图神经网络(GNN)、具有全局注意力机制的 Transformer 架构等^[2]。这些深度学习模型通过更高效的特征编码

策略,实现了对地铁客流时空特征的深度挖掘与智能聚合,将预测能力推向新的高度。本文系统梳理了地铁客流需求预测领域基于深度学习预测方法的研究进展,将现有研究分为:(1)考虑时间特征的预测模型,分析各类神经网络对客流时序动态的建模机制;(2)考虑时空特征的预测模型,剖析时空关联性对地铁客流预测的影响;(3)考虑外部特征的预测模型,研究多源异构数据的协同表示技术;(4)多种方式组合的预测模型,探讨多方法融合和集成学习框架下的模型性能提升策略。

4.1 考虑时间特征的预测模型

自 20 世纪 90 年代起,神经网络开始应用于交通预测领域^[14]。以 RNN 为代表的模型凭借其内部状态记忆机制,能够在长序列中捕捉短期与长期依赖关系,在地铁客流预测任务中展现出显著的方法优势^[2]。然而,传统 RNN 在迭代训练时需在各时间步共享权重并执行链式矩阵乘积,梯度在反向传播过程中会呈指数级衰减或膨胀,分别导致“梯度消失”与“梯度爆炸”,严重制约了模型对长期依赖的表示能力。为破解上述难题,学界相继提出长短期记忆网络(LSTM)和门控循环单元(GRU)等改进结构,通过门控机制实现信息保留与遗忘之间的动态调节,有效延长可学习的时间跨度并稳定梯度传递^[15]。

随着研究的深入,学者们逐渐认识到,即便采用门控机制,循环网络架构在捕捉极长时间依赖、模型并行训练效率以及梯度稳定性等方面仍存在瓶颈^[16]。为突破这些限制,时间卷积网络(TCN)应运而生。TCN 通过因果卷积与空洞卷积相结合,以指数级扩张的感受野高效捕捉长程依赖,同时利用残差连接确保深层网络的梯度稳定,支持并行计算^[17]。然而,传统卷积核固有的固定感受野使其难以在单一网络层次上有效捕捉多尺度的时序依赖关系。基于多头自注意力机制的 Transformer 架构随后被引入时序预测领域,有效突破了 RNN 在建模长期依赖关系方面的固有限制与 TCN 感受野固定、难以捕捉远程依赖的局限^[18]。Transformer 直接在全局范围内对序列元素进行关联计算,通过位置编码保留时序顺序信息,实现了可变长度序列的并行化建模,推动地铁客流预测研究进入了自注意力主导的新阶段。

4.2 考虑时空特征的预测模型

尽管许多研究提取时间特征构造特征方程,但地铁系统的网络特性不容忽视。地铁系统由多个站点及其相连线路构成复杂网络,乘客出行通常跨越多个站点,不同站点客流需求存在显著相关性。这种强相关性不仅体现在相邻站点之间,还可能涉及网络中远距离的换乘站点之间。早期研究通常

为每个站点单独训练预测模型^[11]。然而,这种方法不仅效率低下,还无法捕捉地铁网络中站点间的空间关联性。因此,一些研究在客流预测任务中引入地铁系统的空间特征,更全面地描述客流的复杂出行行为。在这一框架下,地铁系统被表示为一个网络图 $G(V, E, M)$ 。其中: $V = \{v_1, v_2, \dots, v_N\}$ 表示地铁站点集合; E 表示站点之间边的集合; $M \in \mathbb{R}^{N \times N}$ 代表站点之间的邻接矩阵。由此可见,空间特征融合使得特征数量随站点规模的增长呈指数级增加,极大地提升了问题的复杂性,对预测模型的能力和效率提出了更高的要求^[19]。

早期研究采用统计模型、主成分分析等提取地铁客流的空间特征^[20]。随着深度学习在地铁客流预测任务中的应用,显著提升了对高维复杂特征的编码能力,使综合多站点信息的客流预测成为可能。在这类方法中,卷积神经网络(CNN)通过矩阵卷积和池化操作,能够有效编码站点间的交互关系,提取网络中潜在的空间特征,为预测模型提供更丰富的信息输入。Liu 等^[21]将地铁客流的时间依赖性、空间特征以及地铁运营特性等因素进行有效整合,提出基于 LSTM 的神经网络架构,结合 CNN 处理不同站点间的空间依赖关系。

传统 CNN 主要应用于规则的网格数据,然而,地铁网络站点的排列顺序通常是不规则的,站点间的相对位置和连接关系更为重要。因此,尽管 CNN 在处理二维矩阵表示的空间特征方面表现出色,但其难以捕捉非顺序的、基于站点连接关系的空间依赖性。随着神经网络架构的不断发展,图神经网络(GNN)应运而生。GNN 不依赖节点顺序,通过邻接矩阵或图卷积操作,使得每个节点能够根据邻居的特征进行信息传递,更加灵活地建模站点之间的连接性^[22]。不同 GNN 架构提供了不同编码方式,如图卷积网络(GCN)和图注意力网络(GAT)。其中,GCN 通过局部卷积操作聚合邻居节点的特征,例如, Li 等^[23]考虑了站点间的非欧几里得关系,提出了交互图网络模型,通过多通道 GCN 捕捉各站点之间的交互特征,利用双层感知器进行解码,生成站点客流预测结果。GAT 则通过自注意力机制赋予不同邻居节点不同权重,例如,鲁文博等^[24]融合了各车站内部物理拓扑图、线路可达性图、空间距离图等多个局部视图,以单视图车站为中心节点,使用 GAT 学习多视图间动态交互,提升了模型预测的准确度与稳定性。

鉴于 GNN 和 RNN 分别在空间特征编码和时间特征建模上的突出表现,形成了考虑时空特征最常用的 GNN-RNN 网络。通过同时捕捉地铁客流的时间动态性和空间关联性,提升复杂场景下的客流预测能力^[25]。然而, GNN-RNN 架构因其自身复

杂结构,在地铁网络客流预测场景中存在多站点联合预测训练难度大、站点间高阶关系难以表达等局限。Sequence to Sequence(Seq2Seq)结构采用编—解码器的网络架构,擅长处理不同长度的序列数据建模任务,通过编码地铁网络中各站的时序信息,结合特殊设计的解码器结构,将所有站点的客流预测结果进行同步解码,实现全网站点的客流预测。Hao 等^[26]提出了基于注意力机制的 Seq2Seq 模型,构建了由编码器网络和解码器网络组成的整体架构,同时多步地输出地铁网络中各站客流需求预测结果。

4.3 考虑外部特征的预测模型

地铁系统客流需求不仅受地铁内部运营因素的影响,还受到诸多外部因素的影响。因此,构建多源数据融合的预测模型,综合考虑交通网络的联动效应与外部事件的干扰,有助于实现地铁客流的精细化预测。在地铁客流预测研究初期,许多学者就已认识到天气、温度等外部因素对客流需求具有显著影响^[6]。然而,地铁客流还受诸如公交车运行状况、共享单车使用情况、搜索引擎查询、社交媒体动态、土地利用特征等多种外部系统的联动影响。AI 驱动的深度学习方法具备强大的多源多模态数据处理和复杂特征编码能力,不仅能够处理高维、多源的数据输入,还能进行数据融合,揭示外部特征与地铁客流需求间的非线性关系。目前学者们广泛探索了包括公交系统数据、搜索引擎数据、社交媒体数据、建筑环境数据、地理信息系统、兴趣点等多种数据源融合方法。例如:结合公交车运行数据和共享单车使用率,可以更全面地反映城市交通流动状况^[27];利用搜索引擎和社交媒体数据,能够捕捉潜在突发事件和公众出行意愿变化^[28],不仅为地铁运营管理和城市交通规划提供科学的决策支持,也为及时预警突发事件,更有效地预测和管理异常客流提供重要的技术保障^[29]。

在实际运营中管理者常常面临数据不足的挑战,尤其针对异常客流和新线开通场景,缺乏历史客流数据,使得有监督学习方法难以发挥效能^[30]。为了应对异常客流带来的挑战,一些研究从客流数据出发监控客流的异常变化,推演突发客流峰值和时间,提高非常规场景下客流预测性能。另一部分研究对异常客流进行分类。Zhao 和 Ma^[31]使用朴素贝叶斯将客流场景进行二分类,对常规与非常规场景开发特定的梯度提升树与深度学习模型,增强对异常客流的处理能力。此外,部分学者将特殊事件信息融入常规客流预测模型。Xue 等^[32]提出了基于多元干扰的混合深度神经网络模型,针对特殊事件引起的大规模客流波动,在自动售检票系统(AFC)数据基础上,分析社交媒体的动态变化趋势

来提升客流预测的准确性。

新线/站开通场景下的客流预测指在地铁扩展规划阶段,对未来客流需求进行预测。这一场景通常缺乏历史客流数据,一些研究从外部系统挖掘对新线/站客流产生影响的关键特征。Wang 等^[33]从人口分布、兴趣点等潜在因素中识别影响乘客出行的关键特征,开发了特征识别与预测两阶段模型。另一些研究考虑数据增强技术生成潜在客流数据,扩展训练样本的多样性。Zhao 等^[34]通过合成少数群体过采样技术,丰富计划外事件下的客流数据,为模型训练生成数据集。另外,一些半监督学习方法被用于提高数据不足条件下地铁客流的预测能力^[35]。

4.4 多种方式组合的预测模型

4.4.1 参数优化与预测模型结合

参数优化技术能够自动搜索模型的超参数配置,克服了传统人工调参的主观性和低效性。通过系统化的参数空间探索,提升模型在复杂交通预测中的拟合效果和泛化能力。Lai 和 Wang^[36]提出了一种改进的粒子群算法优化 LSTM 网络的超参数,通过调整隐藏层节点数量、学习率和迭代次数,提高算法的全局优化和收敛能力。GNN 模型中涉及图卷积层数、隐藏单元数量、学习率等多个超参数,为提升其泛化性与解释性,Zhang 等^[37]采用动态参数优化方法,基于 GNN-RNN 框架提出了自适应飞蛾扑火优化方法,动态优化参数以避免参数选择不当影响预测精度。此外,诸如粒子群算法、遗传算法等启发式算法,用于优化网络或模型超参数,在许多研究中被广泛应用^[38]。

4.4.2 分解与预测模型融合

时间序列分解可以有效实现特征增强,从复杂的客流数据中提取关键时序信息,增强模型对数据的理解和利用。常用时间序列分解算法包括经验模态分解(EMD)和小波变换(WT)。EMD 将非平稳的时间序列分解为一系列本征模态函数(IMFs)来捕捉局部特性;WT 则通过多尺度分析,有效提取不同频率范围内的时序特征。早在 2012 年,Wei 和 Chen^[39]结合 EMD 与反向传播神经网络(BPN)预测短时地铁客流需求。其中,EMD 将客流序列分解为若干 IMFs,筛选有意义的 IMFs 作为 BPN 的输入,通过 BPN 对选定特征进行训练得到预测结果。一些学者采用 WT 实现时间序列的分解。Xu^[40]将 WT 分别与 CNN-LSTM 和支持向量机(SVM)方法相结合,形成更加灵活的预测框架。其中,WT 将客流数据分解为高频和低频序列,采用 CNN-LSTM 和 SVM 分别对这些高频和低频序列进行学习和预测,最后通过 WT 重新整合得到最终的预测输出。研究表明,这种“分解 + 预测”方法在非线性与非平稳数据中展现出一定的适应能力。

4.4.3 聚类与预测模型耦合

当预测对象呈现显著群体异质性时,采用聚类预处理可有效识别数据内在模式,使后续预测模型能够针对各同质子集构建专属预测器,避免人工定义群体边界的局限性,实现“分而治之”的建模范式。此外,在高维特征场景下,节点邻接矩阵的存储开销与消息传递的计算复杂度呈指数级增长,不仅导致内存占用量激增,更造成模型训练过程中的梯度异常与收敛困难。为应对这些问题,部分学者将聚类方法引入到时空特征建模的上层进行模式识别或特征降维。例如,张惠臻等^[41]使用改进 K-means 聚类算法按客流需求高、中、低将地铁站点划分为三类,集成 LSTM 和 GRU 对不同时段、不同类型站点客流进行预测。Fang 等^[42]采用 K-means 聚类识别具有相似客流变化趋势且位于相似城市功能区域的站点,引入双视图循环图卷积网络以提取地铁交通网络的显性与隐性空间特征。

4.4.4 多种预测方法的集成建模

在预测任务中,集成计量模型、机器学习和深度学习方法能够充分发挥各自优势,形成互补效应。Jing 等^[43]融合了 LightGBM 与 LSTM,引入动态回归选择挖掘局部相关关系,利用局部数据特性匹配最合适的子模型进行预测。Wu 等^[44]提出了结合时间序列分解和强化学习集成策略的混合模型,其中,强化学习对 LSTM、BPN 等多个预测模型进行选择,通过动态调整模型的权重分配,确保了预测结果的鲁棒性和准确性。这种集成策略不仅能够提高预测精度,还能增强模型在不同数据分布下的泛化能力,已被证明在多个领域优于单一方法。

5 大语言模型预测方法

近年来,LLMs 的发展为解决复杂预测问题提供了全新视角。通过海量多领域数据的预训练,构建了丰富的知识表示体系。基于迁移学习机制,将隐含在模型参数中的通用知识高效迁移至下游任务。通过微调预训练模型即可适配地铁客流预测等特定场景,无需从零构建复杂模型架构^[45]。凭借其卓越的语义理解能力,从多源异构数据中自动提取高维抽象特征,深度挖掘数据间的潜在关联,不仅显著提升了预测模型的泛化性能,还增强了模型决策过程的可解释性。

目前,一些研究已开始将 LLMs 应用于交通预测任务,为地铁客流预测研究开辟了新的技术路径。Guo 等^[46]通过 LLMs 解决交通预测中的可解释性与复杂模式识别问题,提出了 xTP-LLM 框架将多模态交通数据转化为自然语言描述,实验结果显示,相比于 GPT-4,所提 xTP-LLM 在 CATraffic zero-shot 数据集上,平均绝对百分比误差优化了

85.11%。针对环境动态变化导致的模型适应性问题,Zhao 等^[47]创新性地 将 LLMs 作为元预测选择器,实时评估多个候选预测分支的输出可靠性,实现了测试阶段的自适应调整,保证了模型在突发交通状况下的预测稳定性。

在模型架构方面,Xu 和 Liu^[45]开发了时空融合大语言模型 GPT4TFP,通过设计多头交叉注意力机制,实现了时空嵌入特征的深度交互建模,配合冻结式微调策略,在保持预训练知识完整性的同时,弥补传统深度学习模型结构复杂且预测效果提升有限的问题。针对数据稀缺场景,Ren 等^[48]提出的 TPLLM 框架,融合 CNN-GCN 双通道特征提取器与 LowRank Adaptation 微调技术,在仅有 10% 训练数据的场景下仍保持高质量预测效果。Huang^[49]采用的语义增强范式将 LLMs 作为高阶文本编码器,融合特殊情境下非结构化文本的语义编码与传统时空特征,提升传统时空预测模型在极端天气等特殊场景下的适应能力。

当前,在地铁客流需求预测这一细分研究领域,LLMs 仍处于探索阶段。Huang 等^[50]利用 LLMs 上下文理解与少样本推理能力,将原始时空数据转化为结构化自然语言描述,采用系统化的提示(prompt)构建多阶段推理链,引导 LLMs 基于文本化的延误事件描述(如“早高峰信号故障持续 30 分钟”)与历史客流时序特征,生成具有时空感知的预测结果。这些开创性研究从不同维度证实,尽管技术路径和优化策略存在差异,LLMs 在智能交通预测领域仍展现出双重突破:一方面,LLMs 通过参数规模效应和注意力机制优势,成功外延了传统深度学习模型在预测精度的边界;另一方面,LLMs 通过自然语言交互界面提供了人类可理解的决策依据。这种预测性能与可解释性的协同提升,标志着智能交通预测正在从传统的黑箱模型向透明化、可交互的新范式演进。

6 现实挑战与未来方向

6.1 精度提升

地铁客流存在高度时空复杂性和动态性,一旦某些关键因素发生变化,真实客流走向可能与历史规律大相径庭,呈现出截然不同的趋势。因此,如何在兼顾稳定历史模式的同时,及时感知客流的动态变化,在高度不确定环境中保证预测模型的精度,依旧是亟待突破的关键挑战。未来研究可从“好数据”“强模型”“新思路”三个方面入手,不断完善技术路线并推动整个领域的进步。

(1) 好数据:统一且真实的评测基准

地铁客流预测研究普遍面临数据不统一、难以公开等问题。不同研究往往使用不同城市、不同线

路和不同时段的数据集,缺乏统一的评测基准。由于隐私和商业限制,相关数据难以开源,研究者缺乏比较基准,不利于模型间优劣的横向对比。为此,迫切需要构建一个具有足够挑战性和真实代表性的地铁客流数据集以及配套统一的评测基准。此外,在应对真实数据匮乏及隐私约束的过程中,数据孪生^[51]和合成数据^[34]技术正逐渐成为潜在的突破口。数字孪生可在虚拟环境中模拟真实地铁系统的运行情境,近似复现地铁客流的动态变化,从而提供更丰富且可控的模拟数据供模型训练。合成数据则能在不侵犯隐私的前提下,基于有限的实际数据生成多样化且高质量的虚拟样本,为学者在极端场景或突发事件下的模型测试和优化提供了更大空间。

(2) 强模型:充分利用先进预测技术

在时间序列预测领域,近年来涌现出大量先进模型,为地铁客流预测提供了新的契机。例如,与视觉 Transformer 相同思路的 PatchTST 可以更好地将地铁客流时序局部特征与地铁系统全局信息相结合^[52]。与扩散模型相结合的 TimeGrad^[53]、CSDI^[54]在建模不确定性和多模态输出方面更具优势。与此同时,TimeGPT^[55]、Lag-Llama^[56]以及 Moirai^[57]等基于 LLMs 的时间序列预测模型,借助大规模预训练展现出更强的表示能力。在时间序列预测榜单 GIFT-Eval 中,排名 Top 10 的模型已有 8 个采用 LLMs 方法,显示出 LLMs 在预测精度提升上的卓越潜力。随着深度学习与 LLMs 技术的持续发展,地铁客流预测的精度和鲁棒性有望得到进一步提升。

(3) 新思路:在线预测与分布偏移应对

地铁系统中乘客行为和环境因素实时变化,固定训练+离线预测的思路难以完全满足实时动态的地铁运营系统。因此,在线预测成为重要方向,通过即时更新模型参数并融合最新地铁系统观测数据,可以提升模型对瞬时变化的响应能力。此外,面对突发事件、节假日或极端天气等分布外场景,传统模型往往出现明显偏差。借助分布外检测和偏移应对方法,可在超出模型已知分布范围时及时触发预警、调整模型,最大限度地降低预测风险^[58]。

6.2 效率增强

随着地铁网络规模的不断扩张及其数字化、智能化要求不断提高,如何更高效、快速地获得预测结果已成为提升地铁服务水平的重要组成部分。目前常用的基于 Transformer 架构的方法尽管在预测精度上表现亮眼,但其自注意力机制对于超大规模数据计算开销过高,导致决策效率受限。因此,如何借助分布式计算与硬件加速,简化网络架构和模型轻量化,提高地铁客流预测效率成为未来研究

的重要挑战和方向。为有效缓解 Transformer 自注意力机制造成的高计算负担,一些研究提出改进的 TS-Fastformer,通过优化网络结构降低计算成本^[59]。一些研究则抛弃 Transformer 架构,转而使用更为简洁的线性模型。例如:DLinear 系列将原始时间序列拆分为趋势和季节性两大成分,分别采用单层线性模型进行训练与预测,大幅缩减了模型规模与推理时间^[60];FITS 模型更进一步将参数数量压缩至 1 万以下,较 DLinear 紧凑约 50 倍,比其他主流模型紧凑约 1 万倍^[61]。这些轻量化方案在保证预测精度的同时,更好地实现了效率保证。除了线性化模型,一些研究探索 Mamba^[62]等新型网络架构,以更好地适配地铁客流预测任务的效率要求。

6.3 透明预测

深度神经网络的“黑箱”使其预测结果难以解释,不仅影响地铁客流预测模型在实际场景中的可信度,也限制了其在政策制定和应急管理中的应用。未来研究应在注重提升预测精度和效率的同时,关注模型的透明性和可解释性。目前较为流行的可解释性方法包括树模型、LIME 和 SHAP。此外,Vielhaben 等^[63]利用离散傅里叶变换和短时傅里叶变换等线性可逆变换,将时间序列数据扩展为频域,通过频域可视化帮助决策者发现影响预测性能的重要特征。Spectral eXplanation 基于时—频解释框架,支持用户将多种解释方法嵌入预训练的时间序列模型中,评估这些方法对解释变量的影响^[64]。除了基于数据和模型的直接解释,知识图谱也是提升解释性的关键技术。构建地铁客流相关知识图谱可以发现影响客流变化的潜在因果链条^[65]。例如,知识图谱可以直观呈现天气变化、大型活动等如何共同影响地铁客流需求,提高模型预测的透明性与决策过程的可靠性。此外,LLMs 可解释特定预测结果逻辑链条,分析预测模型中的关键驱动因素,为透明预测带来新的可能。

6.4 决策对齐

尽管地铁客流预测任务是地铁运营管理的关键环节,但其核心价值在于为列车调度方案制定、运行图优化等后续决策提供可靠的数据支撑。当前主流预测方法普遍采用均方误差、平均绝对误差等统计指标作为训练损失函数,即使能够达到理想的预测精度,但在实际运营场景中,较小的预测误差可能导致较大决策偏差。尤其对于列车编组调整、发车频次调整等高度依赖预测结果的决策任务,微小的预测偏差通过系统级联效应会被显著放大,导致运力配置失衡、能源浪费加剧等问题。

为应对这一挑战,近年来“预测—决策”一体化范式逐渐兴起。一类方法从损失函数重构出发,将列车频次、能源配比等下游优化目标嵌入预测模

型训练过程。例如,Elmachtoub 和 Grigas^[66]提出了 SPO(smart predict-then-optimize)损失函数,在保留凸性前提下引入决策反馈,增强模型的决策导向。另一类方法则通过引入可微优化器,将下游决策模型嵌入神经网络末端,直接使用神经网络生成决策结果,实现端到端的联合训练与反向传播^[67]。未来,构建涵盖地铁客流预测与多类下游决策任务的统一学习框架,实现“预测—决策”闭环联动,将成为提升地铁智慧化运营管理的重要突破口。

参 考 文 献:

[1] 洪永森,汪寿阳. 人工智能新近发展及其对经济学研究范式的影响[J]. 中国科学院院刊, 2023, 38(3): 353-357.

[2] Yin X, Wu G, Wei J, et al. . Deep learning on traffic prediction: methods, analysis, and future directions[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(6): 4927-4943.

[3] Xue Q, Zhang W, Ding M, et al. . Passenger flow forecasting approaches for urban rail transit: a survey[J]. International Journal of General Systems, 2023, 52(8): 919-947.

[4] Xue H, Flora D S. Promptcast: a new prompt-based learning paradigm for time series forecasting[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(11): 6851-6864.

[5] Chen E, Ye Z, Wang C, et al. . Subway passenger flow prediction for special events using smart card data[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(3): 1109-1120.

[6] Tang L, Zhao Y, Cabrera J, et al. . Forecasting short-term passenger flow: an empirical study on Shenzhen metro[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 20(10): 3613-3622.

[7] Cheng Z, Martin T, Sun L. Incorporating travel behavior regularity into passenger flow forecasting[J]. Transportation Research Part C: Emerging Technologies, 2021, 128: 103200.

[8] Lyu T, Xu M, Zhang J, et al. . Influential factor analysis and prediction on initial metro network ridership in Xi'an, China[J]. Journal of Advanced Transportation, 2022, 2022(18): 2842949.

[9] Zhang J, Che H, Chen F, et al. . Short-term origin-destination demand prediction in urban rail transit systems: a channel-wise attentive split-convolutional neural network method[J]. Transportation Research Part C: Emerging Technologies, 2021, 124: 102928.

[10] Yu J, Chang X, Hu S, et al. . Combining travel behavior in metro passenger flow prediction: a smart explainable Stacking-Catboost algorithm [J]. Information Processing and Management, 2024, 61(4): 103733.

[11] Silva D, Shalaby A. Forecasting short-term subway passenger flow using Wi-Fi data: comparative analysis of advanced time-series methods[J]. Journal of Intelligent Transportation Systems, 2024, <https://doi.org/10.1080/15472450.2024.2417175>.

[12] 韩皓,徐圣安,赵蒙. 考虑线网结构的 LightGBM 轨道交通短时客流预测模型[J]. 铁道运输与经济, 2021, 43(10): 109-117.

[13] 周家中,张殿业. 基于空间加权的 LS-SVM 城市轨道交通车站客流量预测[J]. 铁道学报, 2014, 36(1): 1-7.

[14] Dougherty M. A review of neural networks applied to transport [J]. Transportation Research Part C: Emerging Technologies, 1995, 3(4): 247-260.

- [15] Lu W, Zhang Y, Li P, et al. . Mul-DesLSTM: An integrative multi-time granularity deep learning prediction method for urban rail transit short-term passenger flow [J]. Engineering Applications of Artificial Intelligence, 2023, 125: 106741.
- [16] Ma X, Tao Z, Wang Y, et al. . Long short-term memory neural network for traffic speed prediction using remote microwave sensor data [J]. Transportation Research Part C: Emerging Technologies, 2015, 54: 187-197.
- [17] Zhang Y, Sun K, Wen D, et al. . Deep learning for metro short-term origin-destination passenger flow forecasting considering section capacity utilization ratio[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(8): 7943-7960.
- [18] Zhang S, Zhang J, Yang L, et al. . COV-STFormer for short-term passenger flow prediction during COVID-19 in urban rail transit systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25 (5): 3793-3811.
- [19] Hussain E, Bhaskar A, Chung E. Transit OD matrix estimation using smartcard data: recent developments and future research challenges [J]. Transportation Research Part C: Emerging Technologies, 2021, 125: 103044.
- [20] Yang X, Xue Q, Ding M, et al. . Short-term prediction of passenger volume for urban rail systems: a deep learning approach based on smart-card data[J]. International Journal of Production Economics, 2021, 231: 107920.
- [21] Liu Y, Liu Z, Jia R. DeepPF: a deep learning based architecture for metro passenger flow prediction [J]. Transportation Research Part C: Emerging Technologies, 2019, 101: 18-34.
- [22] Huang H, Mao J, Liu R, et al. . MTLMetro: a deep multi-task learning model for metro passenger demands prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(9): 11805-11820.
- [23] Li P, Wang S, Zhao H, et al. . IG-Net: an interaction graph network model for metro passenger flow forecasting [J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(4): 4147-4157.
- [24] 鲁文博,张永,李培坤,等. 自适应多视图融合图神经网络地铁客流预测模型[J]. 交通运输系统工程与信息, 2024, 24(3): 194-203.
- [25] Luo Y, Zheng J, Wang X, et al. . A neural network based on spatial decoupling and patterns diverging for urban rail transit ridership prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24 (12): 15248-15258.
- [26] Hao S, Lee D, Zhao D. Sequence to sequence learning with attention mechanism for short-term passenger flow prediction in large-scale metro system[J]. Transportation Research Part C: Emerging Technologies, 2019, 107: 287-300.
- [27] Yang Y, Zhang J, Yang L, et al. . Network-wide short-term inflow prediction of the multi-traffic modes system: an adaptive multi-graph convolution and attention mechanism based multitask-learning model[J]. Transportation Research Part C: Emerging Technologies, 2024, 158: 104428.
- [28] Tu Q, Zhang Q, Zhang Z, et al. . A deep spatiotemporal fuzzy neural network for subway passenger flow prediction with COVID-19 search engine data[J]. IEEE Transactions on Fuzzy Systems, 2022, 31(2): 394-406.
- [29] Tao Z, Tang J, Hou K. Online estimation model for passenger flow state in urban rail transit using multi-source data[J]. Computer-Aided Civil and Infrastructure Engineering, 2021, 36(6): 762-780.
- [30] Wang H, Li L, Pan P, et al. . Early warning of burst passenger flow in public transportation system [J]. Transportation Research Part C: Emerging Technologies, 2019, 105: 580-598.
- [31] Zhao Y, Ma Z. Naïve Bayes-based transition model for short-term metro passenger flow prediction under planned events [J]. Transportation Research Record, 2022, 2676(9): 309-324.
- [32] Xue G, Liu S, Ren L, et al. . Forecasting the subway passenger flow under event occurrences with multivariate disturbances [J]. Expert Systems with Applications, 2022, 188: 116057.
- [33] Wang K, Wang P, Huang Z, et al. . A two-step model for predicting travel demand in expanding subways[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 19534-19543.
- [34] Zhao Y, Ma Z, Jiang X, et al. . Short-term metro ridership prediction during unplanned events [J]. Transportation Research Record, 2022, 2676 (2): 132-147.
- [35] Wang K, Guo B, Yang H, et al. . A semi-supervised co-training model for predicting passenger flow change in expanding subways [J]. Expert Systems with Applications, 2022, 209: 118310.
- [36] Lai Y, Wang Y. Short-term passenger flow prediction for rail transit based on improved particle swarm optimization algorithm[J]. IET Intelligent Transport Systems, 2023, 17(4): 825-834.
- [37] Zhang Y, Chen Y, Wang Z, et al. . Tmfo-aggru: a graph convolutional gated recurrent network for metro passenger flow forecasting [J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 25(3): 2893-2907.
- [38] Liu J, Jiang R, Zhu D, et al. . Short-term subway inbound passenger flow prediction based on AFC data and PSO-LSTM optimized model [J]. Urban Rail Transit, 2022, 8(1): 56-66.
- [39] Wei Y, Chen M. Forecasting the short-term metro passenger flow with empirical mode decomposition and neural networks [J]. Transportation Research Part C: Emerging Technologies, 2012, 21(1): 148-162.
- [40] Xu Q. Incorporating CNN-LSTM and SVM with wavelet transform methods for tourist passenger flow prediction [J]. Soft Computing, 2024, 28(3): 2719-2736.
- [41] 张惠臻,高正凯,李建强,等. 基于循环神经网络的城市轨道交通短时客流预测 [J]. 吉林大学学报(工学版), 2023, 53(2): 430-438.
- [42] Fang H, Chen C, Hwang F, et al. . Metro Station functional clustering and dual-view recurrent graph convolutional network for metro passenger flow prediction[J]. Expert Systems with Applications, 2024, 247: 122550.
- [43] Jing Y, Hu H, Guo S, et al. . Short-term prediction of urban rail transit passenger flow in external passenger transport hub based on LSTM-LGB-DRS [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(7): 4611-4621.
- [44] Wu J, He D, Li X, et al. . A time series decomposition and reinforcement learning ensemble method for short-term passenger flow prediction in urban rail transit[J]. Urban Rail Transit, 2023, 9(4): 323-351.
- [45] Xu Y, Liu M. GPT4TFP: spatio-temporal fusion large language model for traffic flow prediction [J]. Neurocomputing, 2025, 625: 129562.
- [46] Guo X, Zhang Q, Jiang J, et al. . Towards explainable traffic flow prediction with large language models [J]. Communications in Transportation Research, 2024, 4: 100150.
- [47] Zhao Y, Luo X, Wen H, et al. . Embracing large language models in traffic flow forecasting [J]. arXiv preprint arXiv: 2412.12201, 2024.
- [48] Ren Y, Chen Y, Liu S, et al. . TPLLM: a traffic prediction framework based on pretrained large language

models[J]. arXiv preprint arXiv: 2403.02221, 2024.

[49] Huang X. Enhancing traffic prediction with textual data using large language models[J]. arXiv preprint arXiv: 2405.06719, 2024.

[50] Huang P, He Y, Wang H, et al.. A prompt refinement-based large language model for metro passenger flow forecasting under delay conditions[J]. arXiv preprint arXiv: 2410.15111, 2024.

[51] Zheng H. Research and analysis on the application of digital twin technology in urban rail transit[A]. 2021 IEEE Asia-Pacific Conference on Image Processing, Electronics and Computers (IPEC) [C]. Xi'an, 2021. 1067-1070.

[52] Nie Y, Nguyen N H, Sinthong P, et al.. A time series is worth 64 words: long-term forecasting with transformers[J]. arXiv preprint arXiv: 2211.14730, 2022.

[53] Rasul K, Seward C, Schuster I, et al.. Autoregressive denoising diffusion models for multivariate probabilistic time series forecasting[J]. arXiv preprint arXiv: 2101.12072, 2021.

[54] Tashiro Y, Song J, Song Y, et al.. CsdI: conditional score-based diffusion models for probabilistic time series imputation [J]. Advances in Neural Information Processing Systems, 2021, 34: 24804-24816.

[55] Garza A, Challu C, Mergenthaler-Canseco M. TimeGPT-1 [J]. arXiv preprint arXiv: 2310.03589, 2023.

[56] Rasul K. Lag-llama: towards foundation models for probabilistic time series forecasting[J]. arXiv preprint arXiv: 2310.08278, 2024.

[57] Woo G, Liu C, Kumar A, et al.. Unified training of universal time series forecasting transformers[J]. arXiv preprint arXiv: 2402.02592, 2024.

[58] Lu W, Wang J, Sun X, et al.. Diversify: a general framework for time series out-of-distribution detection and generalization [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46 (6): 4534-4550.

[59] Lee S, Hong J, Liu L, et al.. TS-Fastformer: fast transformer for time-series forecasting[J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15 (2): 1-20.

[60] Zeng A, Chen M, Zhang L, et al.. Are transformers effective for time series forecasting? [A]. Proceedings of the AAAI Conference on Artificial Intelligence [C]. 2023, 37(9): 11121-11128.

[61] Xu Z, Zeng A, Xu Q. FITS: modeling time series with 10 k parameters [J]. arXiv preprint arXiv: 2307.03756, 2023.

[62] Wang Z, Kong F, Feng S, et al.. Is Mamba effective for time series forecasting? [J]. Neurocomputing, 2024, 619: 129178.

[63] Vielhaben J, Lapuschkin A, Montavon G, et al.. Explainable ai for time series via virtual inspection layers[J]. Pattern Recognition, 2024, 150: 110309.

[64] Chung H, Jo S, Kwon Y, et al.. Time is not enough: Time-frequency based explanation for time-series black-box models [J]. arXiv preprint arXiv: 2408.03636, 2024.

[65] Liu Y, Ding J, Fu Y, et al.. Urbankg: An urban knowledge graph system [J]. ACM Transactions on Intelligent Systems and Technology, 2023, 14(4): 1-25.

[66] Elmachtoub A N, Grigas P. Smart “predict, then optimize”[J]. Management Science, 2022, 68(1): 9-26.

[67] Baty L, Jungel K, Klein P S, et al.. Combinatorial optimization-enriched machine learning to solve the dynamic vehicle routing problem with time windows[J]. Transportation Science, 2024, 58(4): 708-725.

AI-Driven Subway Passenger Demand Prediction: Algorithm Innovation and Practical Challenges

Feng Ziyang¹, WANG Xianzhe¹, LI Xiang²
(1. School of Economics and Management, Beijing University of Chemical Technology, Beijing 100029, China; 2. School of Management, Beijing Institute of Technology, Beijing 100081, China)

Abstract:The subway system, with its efficient transport capacity and convenient service mode, has gradually become a core component of urban transportation networks in major cities across China. Accurate passenger demand prediction is beneficial for promoting subway operational planning and train organization operations. However, with the expansion of subway networks and the advancement of smart city development, the dimension of multi-source data has significantly increased.

Subway systems are confronted with formidable challenges in terms of prediction accuracy and management efficiency due to various external factors such as different dates, weather conditions, special events, and other transportation modes. Machine learning, along with other Artificial Intelligence (AI) technologies, has provided novel solutions for tackling complex subway passenger demand prediction tasks. This paper conducts a review of relevant studies published in leading transportation and management journals over recent years, categorizing the literature based on the abilities of AI technologies, covering four main dimensions: statistical predicting methods, machine learning based predicting methods, deep learning based predicting methods, and large language model based predicting methods. By systematically analyzing the key differences among various methods in terms of feature representation, modeling mechanisms, and application scenarios, common characteristics and development trends in current research are summarized. Although each dimension addresses different prediction tasks and analysis perspectives, AI technologies have significantly expanded the boundaries of subway passenger demand prediction, enabling transitions from model-driven to data-driven, static to dynamic, and single-system to fused-data-system, achieving marked progress in model complexity, prediction accuracy, and application scope. Particularly, the emergence of large language models (LLMs) has revolutionized subway passenger demand prediction. By leveraging their exceptional semantic reasoning abilities to decode complex data patterns, LLMs not only improve model generalizability but also enhance interpretability, elevating the field to unprecedented sophistication.

Based on the current research landscape, the practical challenges and future research directions are explored from four aspects: accuracy improvement, efficiency enhancement, transparent prediction, and decision alignment. The discussion aims to provide researchers with a comprehensive understanding of both theoretical advances and practical applications of AI technologies in the subway passenger demand prediction field, facilitating deeper integration and synergistic evolution between AI and subway operations.

Key words:subway system; passenger demand prediction; AI-driven; machine learning; large language model